

מיחשוב ענן רב נתונים – פרויקט סיום

הפרויקט יתבצע בקבוצות של 4-5 סטודנטים לקבוצה.

עבור כל קבוצה יוקצה חשבון עם תקציב על סך 50 דולר ב GCP.

יום לפני תאריך ההגנה יש להעלות למודל (בתיבה שנפתחה לכך) את קוד הפרויקט.

חברת תחבורה מעוניינת לנתח מיליוני נסיעות מוניות כדי להבין:

- מהם המסלולים הפופולריים ביותר בעיר
- אילו אזורים בעיר הם מוקדי פעילות
- כיצד ניתן לזהות מסלולים חריגים
- כיצד ניתן לבצע ניתוחים אלו ביעילות תוך שימוש באלגוריתמים מקורבים Approximate Algorithms בסביבה מבוססת (Spark)

לצורך כך תשתמשו ב Porto Taxi Trajectory Dataset ותבצעו עיבוד מבוסס באמצעות Spark (DataProc) על Google Cloud Platform .

בדאטאסט דוגמים 442 מוניות לאורך שנה שלמה (2013-2014) – סה"כ 1.71M נסיעות, בקצב דגימה של אחת ל 15 שניות למונית.

לינק להורדת הנתונים:

<https://archive.ics.uci.edu/dataset/339/taxi+service+trajectory+prediction+challenge+ecml+pkdd+2015>

שימו לב – הפרויקט מחולק לשלבים – יש לבנות את השלבים בצורה מתועדת. בהגנה תתבקשו להציג תוצרים של כל שלב לפי בחירת המרצה. **כל פעולה** שניתן לבצע אותה באופן יעיל בצורה מקבילית בקלאסטר ה Spark יש לבצעה כך שתבצע באופן היעיל מבחינת:

- זמן ריצה
- מספר הפעולות החישוביות הנדרשות (סיבוכיות) / משבאים

שימו לב שקיבלתם תקציב קבוצתי על מנת לבצע את הפרויקט, השתמשו בו בחוכמה, ניצול יעיל של התקציב משפיע על הציון בפרויקט זה.

שלב 1 – הכנת הנתונים

משימות

1. העלאת הנתונים ל GCS
2. טעינת הנתונים ל Spark (שימו לב כי אתם יכולים גם לעבוד על עותק מקומי של spark כמו שביצענו במעבדה תחת windows, אבל את הניתוח הסופי ומה שתגישו נדרש שתריצו מעל DataProc עם לפחות 5 מכונות שרצות בקלאסטר ב Spark במקביל).
3. ניקוי נתונים פגומים (סעיף פתוח – חישבו מה בנתונים עשוי לפגוע בתוצאות שלכם)
4. חילוף :

- מספר נקודות במסלול
- משך נסיעה
- מרחק משוער


תוצרים

- DataFrame מתועד
- סטטיסטיקות בסיסיות

שלב 2 - Spatial Encoding

עליכם להמיר כל מסלול לרצף של תאים מרחביים. המטרה היא לייעל את החישובים כך שניתן יהיה לתאר מסלולים כמעבר בין תאים במקום לעבוד עם המיקומים המדויקים של ה-GPS. שימו לב כי עבודה עם תאים גדולים מידי עשויה להביא לכך שלא תוכלו להבחין בין מסלולים של כבישים פופולארים הסמוכים זה לזה, מצד שני עבודה עם תאים קטנים מידי תגרור אתכם לבזבז משאבים.

מקובל לעבוד עם אחת מהגישות:

The Global Grid Showdown				
				
	H3	S2	HEALPix	Geohash
Geometry:	Hexagons on Icosahedron.	Quadrilaterals on Cube-to-Sphere.	Equal-area pixels.	Lat/Lon Rectangles.
Best for:	Neighborhood traversal and smoothing. Approximate nesting.	Robust sphere geometry, region coverings, and distributed indexing. Strict hierarchical cell IDs.	Strict scientific, iso-latitude spherical binning (astrophysics, climate).	Simple string-prefix grouping, but suffers heavy distortion near poles.

קיראו על השיטות האלה וביחרו מה הכי מתאים, איזו קונפיגורציה ואף שיקלו לממש גישה משלכם אם אתם רואים בזה ערך.

שלב 3 Popular Long Sub-Route Discovery

המטרה:

לזהות את 100 תתי המסלולים הארוכים הפופולריים ביותר. הכוונה ב"מסלול פופולארי" לא למסלולים מלאים (מתחילת הנסיעה ועד לסיומה) אלא לאוסף של רצפים המהווים מסלול פופולארי וארוך. המסלולים אמורים להיות ארוכים.

מצד אחד לא תרצו למצוא מסלולים פופולאריים קצרים – כי מה שתקבלו כ"מסלולים" אלו צמתים שעברו דרכם מספר גדול של מוניות. מצד שני לא תרצו למצוא מסלולים מלאים כי מן הסתם הם לא יהיו פופולאריים.

לדוגמא בישראל מחלף גנות נחשב מאוד עמוס, אך הוא אינו מהווה "מסלול". נסיעה משוב קטן בצפון שעוברת דרך צומת גנות ומסתיימת בשוב קטן אחר בדרום גם אינה מסלול מעניין כי הוא לא יהיה פופולארי. לכן המפתח לזהות תתי מסלולים ארוכים פופולארים הוא על ידי התניה שבתת המסלול עברו לפחות X%

מהנסיעות (לגבי הערך של X תצטרכו להתנסות בעצמכם עם הדאטה) כאשר אתם מעוניינים למקסם את אורך התת מסלול. אנחנו משתמשים במונח תת מסלול ולא במסלול מלא כי ייתכן למשל שתמצאו שמסלול פופולארי הוא נסיעה מחיפה לאשדוד המתחילה בכביש 4 מחיפה, ומגיעה דרך כביש 4 גם לאשדוד אבל בדרך המסלול לא מכיל את החלקים העוברים באיזור תל אביב כי חלק מהרכבים עברו דרך כביש איילון וחלקם דרך כביש 4 – מכאן שזהו אוסף של תתי מסלולים שעשויים להיווצר "חורים" ביניהם.

בהדגמה תידרשו להציג את 100 תתי המסלולים הארוכים הפופולאריים ביותר בקונפיגורציות הבאות:

- לפחות 1 ק"מ
- לפחות 3 ק"מ
- לפחות 5 ק"מ
- לפחות 10 ק"מ
- לפחות 20 ק"מ
- לפחות 40 ק"מ

ההדגמה תתבצע על גבי מפה בקוד פייתון/מחברת ג'ופיטר תחת Colab Enterprise.

שימו לב כי עליכם לממש מספר דרכים על מנת למצוא את המסלולים , ולפחות:

- שיטה אחת מבוססת Clustering של המסלולים
 - שיטה אחת המבוססת על Suffix Tree/ Suffix Array
 - שיטה אחת שאינה מבוססת אלגוריתמי Clustering או על Suffix – שאתם מציעים
 - לפחות חלק מהמימושים חייבים להראות ייעול באמצעות Approximate Data Structures
- מבוססי Hash כמו
- Bloom Filter
 - Locality Sensitive Hashing
 - Count Min Sketch
 - T-Digest
 - Hyper-LogLog

עליכם להפיק דו"ח מסכם בצורת מצגת המכיל השוואה בין השיטות השונות שמימשתם כולל התייחסות לביצועים, דיוק/רזולוציית המסלולים, זמני ריצה, זיכרון/משאבים וכד'

שימו לב כי לא מדובר ב"רשימת מכולת" שמי שעומד בה מקבל 100 – הרעיון הוא לבחון כיצד אתם מתמודדים עם בעיה ולאיה עומק אתם יכולים להגיע עם הפתרונות עברה. לכן, השקיעו במגוון הפתרונות ובעומק שלהם, תעדו את הניסויים שביצעתם והראו דרכים יעילות ויצירתיות להמודדות עם הבעיה שקיבלתם.

את קוד הפרויקט מגיש סטודנט אחד מכל קבוצה במודל. בהגנה יש להתחבר עם כל חברי הקבוצה.

בהצלחה !